gc_content.py 사용 설명서

FASTQ read 의 GC 비율과 평균 품질 비교 · 생물정보학실험 lab11

1. 개요

FASTQ 파일의 각 read 에 대해 GC 비율과 평균 품질(Phred 점수)을 함께 계산한다. 그다음 GC 비율이 전체 평균에서 가장 많이 벗어난(극단적으로 높거나 낮은) read 10개를 골라, 그 read 들의 평균 품질이 전체 read 의 평균 품질과 차이가 있는지 비교한다. 표준 라이브러리(sys, random)만 사용하므로 기본 환경의 python3 로 바로 실행할 수 있다.

2. 실행 방법

lab11 폴더에서 다음과 같이 실행한다. 두 번째 인자(고를 read 수)는 생략하면 10이다.

```
cd $MYHOME/lab11
python3 src/gc_content.py <FASTQ 파일> [고를 read 수]

# 예시
python3 src/gc_content.py data/SRR1553607_1.fastq
python3 src/gc_content.py data/trimmed.fastq 20
python3 src/gc_content.py data/SRR1553607_1.fastq > doc/gc_content.txt
```

인자 개수가 맞지 않으면 사용법을 표준 오류로 출력하고 종료 코드 1로 끝난다. read 수가 고를 개수보다 많지 않을 때도 오류로 끝난다.

3. 처리 과정

- read_fastq: 4줄 단위로 읽어 (이름, 서열, 품질)을 만든다. 이름은 헤더의 첫 단어(@ 제외)이다.
- gc_ratio: (G 개수 + C 개수) / 서열 길이. 대소문자를 모두 센다. N 은 길이에는 포함되고 GC 에는 포함되지 않는다.
- mean_quality: 품질 문자마다 ord(문자) - 33 (Phred+33) 으로 점수를 구해 평균한다.
- read_stats: read 마다 (이름, 길이, GC 비율, 평균 품질)을 만든다. 트리밍으로 길이가 0이 된 read 는 건너뛴다.
- pick_extremes: 전체 평균 GC 비율과의 차이 |GC - 평균 GC| 가 큰 순서로 정렬해 앞에서 N개를 고른다. 따라서 높은 쪽·낮은 쪽 구분 없이 '가장 극단적인' read 가 뽑힌다. 값이 같으면 파일 순서를 유지한다.
- permutation_test: 전체 read 에서 무작위로 N개를 뽑아 평균 품질을 구하는 일을 10,000번 반복하고, 전체 평균과의 차이가 관찰된 차이 이상으로 벌어진 비율을 양측 p값으로 계산한다. 난수 시드를 1로 고정해 실행할 때마다 같은 결과가 나온다.

4. 출력 형식

결과는 탭으로 구분된 세 부분으로 화면(표준 출력)에 나온다.

- # 전체 read: read 수, 평균 GC 비율, 평균 품질, 품질 표준편차
- # GC 비율이 극단적인 read N개: 이름, 길이, GC비율, 구분(평균보다 높음/낮음), 평균품질
- # 평균 품질 비교: 극단 GC read 평균 품질, 전체 평균 품질, 차이(극단 - 전체), 순열 검정 p값, 결론

5. 실행 예시 (data/SRR1553607_1.fastq)

```
$ python3 src/gc_content.py data/SRR1553607_1.fastq
# 전체 read
read 수    203445
평균 GC 비율    0.5884
평균 품질    33.45
품질 표준편차    6.36

# GC 비율이 극단적인 read 10개 (평균 GC 에서 벗어난 정도 순)
이름    길이    GC비율    구분    평균품질
SRR1553607.166164    101    0.1287    낮음    39.66
SRR1553607.165570    101    0.1386    낮음    38.32
SRR1553607.179986    101    0.1386    낮음    38.09
SRR1553607.59968    101    0.1584    낮음    39.58
SRR1553607.61985    101    0.1584    낮음    33.28
SRR1553607.70984    101    0.1584    낮음    39.22
SRR1553607.117728    101    0.1584    낮음    39.27
SRR1553607.117814    101    0.1584    낮음    37.28
SRR1553607.166721    101    0.1584    낮음    40.11
SRR1553607.172662    101    0.1584    낮음    38.46

# 평균 품질 비교
극단 GC read 평균 품질    38.33
전체 read 평균 품질    33.45
차이(극단 - 전체)    +4.88
순열 검정 p값(10000회)    0.0198
결론    극단 GC read 의 평균 품질은 전체 평균과 유의하게 다르다 (p < 0.05).
```

6. 결과 해석

SRR1553607_1.fastq 의 평균 GC 비율은 약 0.59 로 높은 편이어서, 평균에서 가장 멀리 떨어진 read 10개는 모두 GC 비율이 0.13~0.16 인 '낮음' 쪽에서 나왔다. 이 read 들의 평균 품질(38.33)은 전체 평균(33.45)보다 약 4.9 높았고, 순열 검정 p값은 약 0.02 로 0.05 보다 작아 무작위로 고른 10개에서는 잘 나오지 않는 차이이다.

다만 비교 대상이 10개뿐이라 결과가 몇 개 read 에 크게 좌우된다. trimmed.fastq 에 개수 5로 실행하면 차이는 +2.73, $p \approx 0.08$ 로 유의하지 않게 나온다. 고를 read 수를 바꾸거나 원본·트리밍 파일을 비교해 결론이 얼마나 안정적인지 함께 확인하는 것이 좋다.

7. 주의 사항

- 품질 인코딩은 Phred+33 으로 가정한다 (현재 Illumina 데이터의 표준).
- FASTQ 한 레코드가 정확히 4줄이어야 한다 (서열·품질이 여러 줄로 나뉜 파일은 지원하지 않음).
- 파일 전체를 메모리에 읽는다. 약 20만 read(80만 줄) 파일은 2초 정도 걸린다.
- 순열 검정 p값은 무작위 추출에 기반한 근삿값이며 최솟값은 $1/10001 \approx 0.0001$ 이다.