qual_summary.py 사용 설명서

생물정보학실험 lab11 · 파일 위치: lab11/src/qual_summary.py · 작성일 2026-11-10

1. 개요

FASTQ 파일의 모든 read 에 대해 품질 문자열을 Phred 점수로 바꿔 **read 별 평균 품질**을 구하고, 그 값들을 다시 평균 내어 **전체 read 평균 품질** 한 줄을 출력하는 스크립트다. 파이썬 표준 라이브러리(`sys`)만 사용하므로 별도 설치 없이 기본 python3 로 실행할 수 있다.

2. 실행 방법

인자로 FASTQ 파일 경로 하나를 받는다. 저장소 루트(`$MYHOME`)에서 실행하는 예:

```
python3 lab11/src/qual_summary.py lab11/data/SRR1553607_1.fastq
python3 lab11/src/qual_summary.py lab11/data/SRR1553607_2.fastq
```

lab11 폴더 안에서 실행하는 경우:

```
cd $MYHOME/lab11
python3 src/qual_summary.py data/SRR1553607_1.fastq
```

R1, R2 를 한 번에 돌리고 결과를 파일로 남기려면:

```
cd $MYHOME/lab11
for f in data/SRR1553607_1.fastq data/SRR1553607_2.fastq; do
    echo -n "$f  "; python3 src/qual_summary.py "$f"
done > doc/qual_summary.txt
```

3. 실행 결과 예시

lab11/data 의 paired-end 파일 두 개에 대해 실행한 실제 출력이다 (각 약 1초 소요).

```
$ python3 src/qual_summary.py data/SRR1553607_1.fastq
전체 read 평균 품질: 33.4497222958299

$ python3 src/qual_summary.py data/SRR1553607_2.fastq
전체 read 평균 품질: 30.830840894308746
```

파일	read 수	read 길이	평균 품질	품질 범위
SRR1553607_1.fastq (R1)	203,445	101 (모두 동일)	약 33.45	2 ~ 41
SRR1553607_2.fastq (R2)	203,445	101 (모두 동일)	약 30.83	2 ~ 41

해석: 두 파일 모두 평균 Q30 이상(오류 확률 0.1% 이하)으로 품질이 좋은 편이다. R2 가 R1 보다 약 2.6 낮은데, Illumina paired-end 에서 R2 의 품질이 R1 보다 낮은 것은 흔한 현상이다.

4. 품질 점수(Phred+33) 읽는 법

FASTQ 의 4번째 줄은 염기 하나당 문자 하나로 품질을 기록한다. 문자의 ASCII 코드에서 33 을 빼면 Phred 품질 점수 Q 가 되고, Q 는 그 염기가 틀렸을 확률 P 와 $Q = -10 \times \log_{10}(P)$ 관계를 가진다.

문자	ASCII	Q = ASCII - 33	오류 확률	의미
`#`	35	2	약 63%	매우 나쁨 (이 데이터의 최저값)
`5`	53	20	1%	흔히 쓰는 최소 기준 Q20
`?`	63	30	0.1%	좋은 품질 기준 Q30
`J`	74	41	약 0.008%	최고 품질 (이 데이터의 최고값)

예) 품질 문자열 `BB@F` → B(66-33=33), B(33), @(64-33=31), F(70-33=37) → 평균 (33+33+31+37)/4 = 33.5

5. 코드 설명

```
1  import sys
2
3  def read_fastq(filename):
4      records = []
5      with open(filename) as f:
6          lines = f.readlines()
7      for i in range(0, len(lines), 4):
8          name = lines[i].rstrip()[1:]
9          seq = lines[i + 1].rstrip()
10         qual = lines[i + 3].rstrip()
11         records.append((name, seq, qual))
12     return records
13
14 def mean_quality(qual):
15     scores = []
16     for ch in qual:
17         scores.append(ord(ch) - 33)
18     return sum(scores) / len(scores)
19
20 reads = read_fastq(sys.argv[1])
21
22 total = 0
23 for name, seq, qual in reads:
24     q = mean_quality(qual)
25     total = total + q
26
27 print("전체 read 평균 품질:", total / len(reads))
```

줄	설명
1	`sys` 모듈을 불러온다. 명령줄 인자(`sys.argv`)를 쓰기 위해서다.
3-12	`read_fastq` : 파일 전체를 `readlines()` 로 읽은 뒤 4줄씩 건너뛰며 (이름, 서열, 품질) 튜플의 리스트를 만든다. 이름은 '@' 를 뗀 1번째 줄, 서열은 2번째 줄, 품질은 4번째 줄이며 3번째 줄('+')은 쓰지 않는다. `parse_fastq.py` 의 함수와 같다.
14-18	`mean_quality` : 품질 문자열의 각 문자 `ch` 를 `ord(ch) - 33` 으로 Phred 점수로 바꿔 리스트에 모은 뒤, 합을 개수로 나눠 그 read 의 평균 품질을 돌려준다.
20	첫 번째 명령줄 인자를 파일 이름으로 넘겨 모든 read 를 읽는다.

줄	설명
22-25	read 마다 평균 품질 `q` 를 구해 `total` 에 누적한다. `name`·`seq` 는 꺼내기만 하고 사용하지 않는다.
27	누적 합을 read 개수로 나눠 **read 평균 품질들의 평균**을 출력한다. 소수점 반올림은 하지 않는다.

6. 계산 방식에 대한 참고

이 스크립트가 출력하는 값은 "read 별 평균의 평균"이다. 모든 염기의 품질을 한꺼번에 평균 낸 "염기 단위 평균"과는 read 길이가 서로 다를 때 값이 달라진다(짧은 read 의 비중이 커짐). 이번 데이터는 모든 read 가 101 bp 로 같아서 두 값이 일치하는 것을 확인했다 (R1 33.4497…, R2 30.8308…).

소수점 둘째 자리까지만 보고 싶다면 27번째 줄을 다음처럼 바꿀 수 있다 (선택 사항):

```
print("전체 read 평균 품질:", round(total / len(reads), 2))
```

7. 주의 사항 및 한계

- **인자 누락**: 파일 경로 없이 실행하면 `IndexError: list index out of range` 로 종료된다.
- **빈 파일**: read 가 0개면 마지막 줄에서 `ZeroDivisionError: division by zero` 가 난다. 품질 줄이 비어 있는 read 가 있어도 `mean_quality` 에서 같은 오류가 난다.
- **엄격한 4줄 형식 가정**: 서열·품질이 여러 줄로 나뉜 FASTQ, 빈 줄이 섞인 파일, 줄 수가 4의 배수가 아닌 잘린 파일은 잘못 읽히거나 `IndexError` 가 난다.
- **Phred+33 전용**: 오래된 Illumina 1.3~1.7 의 Phred+64 인코딩 파일은 점수가 31 씩 높게 계산된다.
- **메모리·압축**: 파일 전체를 메모리에 올리므로 수 GB FASTQ 에는 적합하지 않다 (56 MB 는 약 1초). `.fastq.gz` 압축 파일은 먼저 `gunzip` 으로 풀어서 사용한다.
- **요약값 하나만 출력**: 위치별 품질 저하, 저품질 read 비율 등은 알 수 없다. 자세한 품질 진단은 서열 분석 환경(3-seq)의 `fastqc` 를 사용한다.

8. 함께 쓰면 좋은 명령어

```
# read 개수 확인 (줄 수 ÷ 4)
echo $(( $(wc -l < data/SRR1553607_1.fastq) / 4 ))

# 첫 read 의 품질 줄(4번째 줄)만 보기
sed -n '4p' data/SRR1553607_1.fastq

# 같은 폴더의 read 정보 확인 스크립트
python3 src/parse_fastq.py data/SRR1553607_1.fastq
```